

난이도는 있어도 계산량과 연결되지 않는다: 파킨슨 필기 스크리닝의 동적 정적 경량화 비교

이우림, 원종윤, 박민규, 임시연

Difficulty Without Cost-Coupling: Comparing Dynamic and Static Compressions for Parkinsonian Handwriting Screening

Woo Rym Lee, Jong Yoon Won, Min Kyu Park, Si Yeon Iim

Abstract In handwriting-based Parkinson's disease screening, a 38-MFLOPs model processed a 2-second signal in 7.8 ms on a single laptop CPU core, reaching a window-level ROC-AUC of .851 - a mean loss of 0.012 relative to a 3,499-MFLOPs reference model, within a pre-registered equivalence margin.

Computation-reduction approaches fall into three axes: dynamic (Early Exit), static(reducing depth, width, or patch size), and representation-based (domain features). Only the dynamic axis assumes that required computation varies across inputs. Testing this along depth, subject, and time, we found genuine difficulty variance, but additional computation failed to rescue the subjects who were actually difficult. In contrast, just 4 of 54 candidate features reached .7974 - about 93% of reference performance - indicating that discriminative information is largely low-dimensional. This advantage held after controlling for age, measurement year, and recording-boundary confounds. Occlusion analysis further showed that only the patients' axial-pressure channel carried a reproducible 4-6 Hz signal in the model's evidence regions. For this dataset, static compression proved a more direct deployment solution than Early Exit, which allocates computation per input.

Keywords Parkinson's disease screening, handwriting analysis, Early Exit, model compression, PatchTST, equivalence testing, occlusion analysis

1. 서론

필기 기반 파킨슨병 스크리닝은 저비용 선별 검사로 주목받아 왔고, 온디바이스 배포를 염두에 두면서 계산량 축소가 함께 다뤄진다. 계산을 줄이는 방법은 크게 세 축으로 볼 수 있다. 동적 축은 Early Exit을 이용해 쉬운 입력을 얇은 층에서 종료하는 방식이고, 정적 축은 층 수·폭·패치 크기를 줄이는 방식이다. 표현 축은 도메인 특징을 추출한 뒤 경량 분류기로 판별하는 방식이다.

이 가운데 Early Exit만은 별도의 전제를 필요로 한다. 입력 간 예측 난이도에 유의한 분산이 존재해야 서로 다른 입력에 서로 다른 계산량을 배분할 이유가 생긴다. 하지만 실제 연구에서는 이 전제가 충분히 검증되지 않은 채 방법론이 먼저 제안되는 경우가 있다.

본 연구는 이 전제를 명시적으로 조건으로 두고, 난이도 분산이 존재하는지와 그 난이도가 계산량 요구와 연결되는지를 깊이·사람·시간의 세 방향에서 확인한다. 동시에 연령, 측정 연도, 기록 경계와 같은 데이터셋의 지름길을 차단하고, 모델이 실제 필기 신호의 어떤 구간을 근거로 사용하는지 Occlusion 기반으로 분석한다.

연구의 핵심 기여

- ① Early Exit 실패 원인 규명: 깊이·사람·시간의 세 방향에서 입력 난이도의 분산은 실재하지만, 어려운 입력과 추가 연산으로 개선되는 입력이 일치하지 않아 Early Exit이 실패함을 보였다.
- ② 판별 정보의 저차원성: 54개 후보 중 도메인 특징 4개가 참조 모델 AUC의 93%를 설명해, 연산을 늘려도 성능이 오르지 않는 이유를 제시했다.
- ③ 실측 기반 경량 모델: 깊이가 아니라 패치 길이와 폭을 줄인 d64L2가 참조 모델 대비 연산량을 91배 줄이면서 평균 AUC 손실을 0.12(윈도우 AUC .851)로 억제하며, 노트북 CPU 코어 1개에서 7.8ms에 동작함을 보였다.
- ④ 교란을 통제된 평가와 근거 분석: 피험자 단위 분할과 연령·측정 연도·기록 경계 통제 아래에서 모델이 연령을 대리 학습하지 않음을 확인하고, occlusion 분석으로 환자의 축압력 채널 근거 구간에 4-6Hz 떨림 대역이 집중됨을 보였다.

2. 데이터 및 평가 방법

NewHandPD[1]는 스마트펜 6채널을 1000Hz로 기록하고 네 종류의 필기 과제를 포함한다. 파일 번호는 66개지만 Person_ID_Number를 기준으로 세면 고유 피험자는 61명이며, 정상군 35명과 환자군 26명으로 구성된다. 중복 4건과 인물 혼입 1건이 확인되어 파일 단위 분할을 사용할 경우 같은 사람이 학습과 평가 양쪽에 들어갈 수 있다. 본 연구에서는 피험자 단위로 분할했다.

신호는 2초 길이의 윈도우로 자르고 50% 중첩을 적용해 13,474개 윈도우를 구성했다. 분류기는 PatchTST[8]에 RevIN[9] 정규화를 포함한 구조를 사용했으며, 평가는 피험자 단위 GroupKFold로 수행했다. 기본 실험은 seed 42/1/7 을 사용하고, 주 평가지표는 윈도우 단위 ROC-AUC로 두었다. 피험자 단위 정확도는 피험자 수가 61명에 불과해 한 명의 변화가 약 1.64%p에 해당한다는 점을 고려해 보조 지표로 사용했다.

3. 교란 통제


이 데이터셋은 2016년 측정 21명이 전원 정상이고 정상군이 환자군보다 평균 14.7세 젊다. 따라서 나이 하나로 자르는 규칙만으로도 73.8%가 맞는다(임계 53세). 모델이 넘어야 할 기준은 단순 다수결 57.4%가 아니라 이 연령 규칙이다.

조건	인원 / 연령차	연령 규칙 (임계)	모델 (피험자 정확도)	모델 - 규칙
R0 전체 61	+14.7세	0.738 (53세)	0.813	+0.075
R4 2016년 제외 40	+11.3세	0.775 (48세)	0.849	+0.074
R5 45세 이상 41	+3.3세	0.659 (53세)	0.805	+0.146

표 1. 교란 통제 조건별 성능. 연령 규칙은 각 조건에서 임계값을 재최적화했다.

세 조건은 동일한 d64 계열 백본을 사용해 3-fold seed 42/1/7로 학습했다. 연령차를 3.3세로 좁힌 R5에서 연령 규칙은 .659로 다수결(.585)에 가까워졌지만 모델은 .805를 유지했다. 따라서 규칙 대비 우위가 +.075에서 +.146으로 커진다. 만약 모델이 연령을 대리 학습했다면 연령 정보가 약해질 때 모델도 함께 무너지는 방향을 예상해야 하지만, 관측값은 반대였다.

교란 통제 조건별 모델 및 기준선 정확도



조건별 연령 규칙 대비 모델 정확도 차이




그림1. 연령 교란을 단계적으로 줄였을 때의 모델, 연령 규칙 비교

같은 절차를 배포 모델 d64L2(patch 100/50 · 64 · L2)에서도 재현했다. 아래 표는 절대 성능 자체보다 교란 통제의 방향이 다른 백본에서도 유지되는지를 확인하기 위한 것이다.

조건	연령 규칙	다수결	모델	모델 - 규칙	윈도우 AUC
R0 전체	.738	.574	.819	+.081	.8434
R4 2016년 제외	.775	.650	.833	+.058	.8511
R5 45세 이상	.659	.585	.837	+.178	.8370

표 2. 모델 d64L2에서의 교란 통제 재현.

세 번째 의심은 측정 아티팩트다. 각 기록의 시작·종료 구간에는 펜을 들고 내려놓는 준비 동작이 섞일 수 있으므로, 모델이 질환보다 이 경계를 학습했을 가능성을 확인했다. 피험자 fold를 먼저 고정된 뒤 train·validation·test 모두에서 기록별 첫·마지막 윈도우를 제거해 13,474개에서 11,890개로 줄이고 재학습했다.

조건	윈도우 수 (정상/환자)	피험자	윈도우(AUC)	피험자 hard 정확도	피험자 soft 정확도
기존 L1	13,474 (4,867/8,607)	61명	.8664	.8846	.9068
R2 첫 마지막 윈도우 제거	11,890 (4,027/7,863)	61명	.8691	.8748	.8915
R2 - 기존	-1,584 (-840/-744)	유지	+.0027	-.0098	-0.154

표3. p16d128L1에서의 기록 경계 윈도우 제거 전후 비교.

792개 기록과 61명은 모두 유지됐고 윈도우 AUC는 .8664에서 .8691로 떨어지지 않았다. 피험자 hard 정확도는 .8846에서 .8748로 낮아졌지만, 그 폭은 피험자 1명에 해당하는 약 .016보다 작다. 다만 경계 창을 제거하면서 학습량과 평가 창 구성이 함께 바뀌었고, 정상 기록이 더 짧아 정상 창이 상대적으로 더 많이 제거됐다. 또 윈도우가 50% 겹치므로 경계 창의 일부 샘플은 이웃 창에 남는다. 기존 결과에는 fold별 원본이 없어 전후 차이의 신뢰구간과 동등성 검정은 계산하지 못했다. 따라서 이 결과는 경계 의존이 없다는 증거가 아니라, 기록 경계가 있어야만 성능이 나온다는 설명을 약화시키는 근거로 해석한다.

4. Early Exit 성립 조건의 검증

Early Exit이 의미 있으려면 입력마다 필요한 계산량이 달라야 한다. 본 연구에서는 이 조건을 실제 난이도 분산, 난이도와 추가 계산의 연결, 시간에 따른 종료 신호, 조기 종료 후 오류 통제의 네 단계로 나누어 확인했다.




그림 2. 입력 난이도 분산과 계산량 증가에 따른 성능 변화.

시험자별 판정 명확도를 $p=0.5$ 로 정의했을 때, 0.1 미만인 애매한 피험자는 11명이며 seed별로는 10~13명(16~21%)이었다. 즉 입력 난이도는 일정하지 않다. 이론적으로 관측량을 적게 사용해 종료할 수 있는 절감 여지 또한 98.5%로 계산되며, 시간 축에서는 증거 누적에 따른 드리프트와 정확도 사이에 $r=+0.34$, $p=.007$ 의 관계가 관측됐다.

조건	판정	관측값
절감 여지가 있는가	O	이론 상한 98.5%
난이도 분산이 있는가	O	명확도 상하위 4.8배, 분포 단봉 아님
멈출 신호가 있는가	O	드리프트 ↔ 정확도 $r=+0.34$ ($p=.007$)
오류를 통제할 수 있는가	X	확신 오분류 피험자 8명

표 4. 시간 축 조기 종료의 성립 조건.

4.1 깊이 축

같은 백본에서 층 수만 바꿔 독립 학습한 결과, L1의 윈도우 AUC는 .8664($\pm$.003), L6은 .8629($\pm$.002)였다. 연산량은 약 6배 차이가 나지만 깊은 모델의 개선은 없었고 L6이 L1보다 0.35%p 낮았다. 시드 단위 TOST에서 L1은 L6과 동등성 마진 .02 안에 들었다 ($p=.003$, 90% CI [-.0003, +.0073]). 다만 같은 조건을 재측정한 fold 단위 분석 (L1 .8643, L6 .8615)에서는 90% 구간이 [-.029, +.035]로 마진을 벗어났다. 이처럼 동등성 판정이 분석 단위에 좌우되므로, 정확한 표현은 ‘차이가 없다’가 아니라 ‘이 표본에서 검출 가능한 크기의 차이가 아니다’이다.

Early Exit은 d64 계열 6층 모델의 각 층에 분류 출구를 달고, 출구의 최대 softmax 확률이 임계값 τ 이상이면 그 층에서 종료하도록 구성했다. 설정 문제의 가능성을 배제하기 위해 출구 손실 가중 3중(균등·깊은 층 강화·얕은 층 강화), 확신도를 쓰지 않는 PABEE 종료 규칙, $\tau = 0.50 \sim 1.00$ 의 21개 값을 시험했다. 어느 가중에서도 6개 층을 모두 사용한 경우($\tau = 1.00$, 109MFLOPs)와 1층에서 모두 종료한 경우($\tau = 0.50$, 21 MFLOPs)의 시드 평균 AUC 차이는 -.004~+.001에 그쳐, 연산을 5배 더 써도 판별력이 개선되지 않았다. 2클래스 문제에서 최대 softmax는 항상 0.5 이상이므로 $\tau = 0.50$ 은 모든 입력을 1층에서 종료시키는 정적 모델과 같다. τ 를 올리면 평균 종료 층이 점진적으로 깊어질 뿐($\tau = 0.60$ 에서 약 1.3층), 어려운 입력만 깊은 층으로 보내는 선택적 라우팅은 관측되지 않았다.

4.2 사람 측

세 시드에 걸쳐 한 번 이상 오분류된 피험자는 12명이었다. 이 중 일관 오분류 피험자(3/3)는 2명이었고, 나머지 10명(2/3: 4명, 1/3: 6명)은 시드에 따라 판정이 달라지는 시드 의존 오분류였다. seed 42에서 깊이를 L1에서 L6으로 늘렸을 때 순이득은 3명(개선 4명, 악화 1명)에 불과했고, 피험자 확률은 평균 0.083만 움직였다. 일관 오분류 2명은 L1과 L6 모두에서 틀렸다. 즉, 깊이는 시드 의존 오분류 일부를 흔들 뿐 일관 오분류는 해소하지 못했다.

4.3 시간 측

피험자마다 윈도우 증거를 시간순으로 누적해, 판정에 필요한 관측량을 SPRT의 Wald 근사[11]로 분석했다. 필요 관측량의 중앙값은 윈도우 2개로 이론적 절감 여지는 최대 98.5%였다. 그러나 정답과 반대 방향으로 증거가 쌓이는 고확신 오분류 피험자가 시드별로 7~9명 나타났고(seed 42에서 8명 중 7명이 환자), 사전확률 보정(-3~+4)이나 온도 보정으로도 이 인원은 줄지 않았다. 즉 순차 종료는 관측량을 줄이는 대신 이들의 오분류를 더 일찍 확정할 뿐이어서, 시간 측에서도 적응적 종료의 이득은 없었다.

4.4 종합

세 방향의 결과는 같은 형태를 보인다. 사람 측에서 입력 난이도의 차이는 분명히 존재했지만, 깊이를 늘려도 일관 오분류 피험자는 구제되지 않았고, 시간 측의 순차 종료는 고확신 오분류를 더 일찍 확정할 뿐이었다. 따라서 Early Exit의 실패는 난이도 분산이 없어서가 아니라, 실제로 어려운 입력과 추가연산으로 나아지는 입력이 같은 집합이 아니기 때문이다.

5. 판별 정보의 차원

Early Exit이 실패하는 이유를 특징 공간에서 추가로 확인했다. 후보 특징은 0.5-4, 4-6, 6-12, 12-50Hz의 네 대역 파워를 6채널에 대해 계산하고, 속도·가속도·진폭의 표준편차, 첨도, 정지 시간 비율을 더해 총 54개로 구성했다.

특징 선택에서는 선택 편향을 구분했다. 전체 데이터에서 단일 성능 순위를 매기는 fixed 방식은 평가집합 정보가 순위에 섞일 수 있으므로 결론의 근거로 사용하지 않았다. 대신 각 fold의 검증집합에서만 greedy 선택을 수행했다.




그림 3. 후보 54개 중 특징 수를 늘렸을 때의 윈도우 ROC-AUC.

편향을 피한 greedy 곡선은 k=4에서 .7974로 사실상 포화했고, k=5~8에서도 .7980~.8004 사이를 오갔다. 피험자 AUC는 .9053에서 .8979로 오히려 내려갔다. 반면 fixed 방식은 k=5에서 .8343까지 올라가 참조 모델과의 격차를 2.9%p로 좁혔지만, 이 값은 선택 편향 때문에 결론의 근거로 사용하지 않았다.

4개의 특징만으로 참조 모델 AUC의 약 93%를 얻었다는 결과는 판별 정보가 대체로 저차원이라는 해석을 지지한다. 다만 저차원 측 자체가 떨림 대역인 것은 아니다. 4~6Hz 대역 파워를 6채널 모두 사용해도 AUC는 .6125였고, 단일 특징 중 최고는 그림력의 가속도 표준편차(.7274)였다. 단일 성능 상위 8개에는 떨림 대역 특징이 하나도 없었다.

따라서 포화 지점의 잔차는 $.8629 - .8004 = 6.25\%p$ 로 남는다. 본 결과가 뒷받침하는 것은 판별 정보가 대체로 저차원이라는 것이지 전부 저차원이라는 것은 아니다. 또한 가속도 표준편차와 저주파 성분은 연령과 함께 변할 수 있으므로, 이 절의 결과가 연령 교란의 재등장이라는 해석을 막기 위해서는 앞 절의 교란 통제 결과에 의존해야 한다.

6. 설명 분석: 모델의 근거 구간

저차원성은 ‘왜 더 계산해도 안 풀리는가’를 설명하지만, 모델이 실제로 어떤 신호를 근거로 판단하는지는 별도의 질문이다. 이를 확인하기 위해 학습된 모델을 고정한 채 입력의 1초 구간을 채널별로 제거하고, 예측 확률이 얼마나 변하는지를 측정하는 Occlusion 분석을 수행했다.

변화가 큰 구간을 해당 채널의 근거 구간으로 정의한 뒤, 근거 구간과 나머지 구간의 4-6Hz 상대 파워를 피험자 안에서 비교했다. 절대 파워 대신 대역 파워를 전체 파워로 나눈 상대파워를 사용해 진폭 차이의 영향을 줄였다. 또한 학습에 사용된 피험자를 자기 설명에 다시 사용하는 것을 피하기 위해 독립 test_subjects에서 평가했으며, 구간 라벨을 1,000회 순열해 귀무분포를 만들고 6채널에 Holm 보정을 적용했다.

[그림4]




그림 4. Occlusion 근거 구간의 4-6Hz 상대 파워와 과제별 효과.

6채널x2군의 12개 검정 중 환자의 축압력 채널 하나만 세 seed에서 모두 유의했다. 효과크기 d_z 는 +0.870/+0.867/+0.819, 순열 z는 +6.06/+7.93/+4.94, Holm 보정 p는 .0008/.0030/.0063 이었다. 환자 26명 중 22명이 같은 방향을 보였고, 정상군의 같은 채널은 seed마다 부호가 뒤집혀 보정 후 $p=1.0$ 이었다.

근거 구간을 평균값으로 대체하는 대신 선형보간으로 채워도 효과가 +1.02로 유지됐다. 과제별로는 나선 +0.80, 구불선 +0.65, 원 +0.41, 손뒤집기 -0.11 순서였다. 펜 끝이 종이에 그림을 그리는 과제에서 떨림 근거가 강하고 손을 뒤집는 과제에서는 사라지는 패턴이다. 과제별 독립 분류에서 원 그리기의 AUC가 .408로 나타난 결과와도 방향이 일치한다.

다만 이 결과는 상관이며 인과를 의미하지 않는다. 4-6Hz 대역을 제거한 뒤 재학습하면 AUC가 .8664에서 .8674로 회복되므로 해당 정보는 다른 특징과 중복되어 있다. 고정 모델에서 4-6Hz 제거의 효과도 환자 +.036, 정상 -.021 수준이었다. 즉 모델은 떨림 관련 정보를 사용하지만 떨림만으로 판단하지 않는다.

7. 세 축의 비교와 배포 비용

구성	연산량 (MFLOPs)	윈도우 AUC (seed 3개 평균 $\pm$ SD)
참조 모델 p16d128L6	3,499	0.8629 $\pm$.003
층만 줄임 p16d128L1	588	0.8664 $\pm$.003
패치 $\uparrow$ 폭 $\downarrow$ d64L2	38	0.8511 $\pm$.011
회귀	$\sim$ 0.001	0.7974

표 5. 세 축의 연산량과 성능. 절대 성능표는 5-fold, seed 42/1/7 기준이다.

참조 모델 대비 d64L2의 평균 성능 손실은 -.012로 사전 등록한 동등성 마진 .02 안이며, d64L2의 시드 변동 $\pm$.011과 같은 크기다. 층을 줄이는 것만으로도 AUC는 유지되지만 연산량은 588 MFLOPs에 남는다. 반면 패치 길이를 키우고 폭을 줄인 d64L2는 38 MFLOPs까지 낮아진다.

모델	MFLOPs	중앙 지연	p90	초당 처리 윈도우
d64L2	38	7.8 ms	10.7 ms	128
p16d128L1	588	46.7 ms	52.8 ms	21
p16d128L6	3,499	380.9 ms	437.8 ms	2.6

표 6. 노트북 CPU 코어 1개, batch=1 에서 측정한 추론 지연.

d64L2는 2초 신호를 중앙값 7.8ms에 처리하므로 실시간의 약 256배 속도로 동작한다. 다만 이론 FLOPs가 91배 줄어든 것에 비해 실제 지연은 약 49배만 줄었다. 이는 메모리 대역폭 등 하드웨어 병목이 존재하므로 FLOPs만으로 배포 비용을 주장해서는 안 된다는 점을 보여준다.

p16d128L1은 층이 1개인데도 588 MFLOPs가 필요하다. 패치 크기 16에서 길이 2,000의 시계열은 각 249개 패치로 나뉘고, 어텐션 비용이 패치 수의 제곱으로 증가하기 때문이다. d64L2는 패치 100으로 약 39개 패치만 만들고 폭도 절반으로 줄여 약 15배 낮은 연산량을 달성한다. 이 과제에서 유효한 정적 축은 단순한 깊이 축소보다 패치 길이와 폭 축소였다.

연산이 극도로 제한된 경우에는 표현 축도 의미가 있다. 4개의 도메인 특징은 약 0.001 MFLOPs로 참조 모델의 약 93% 수준의 AUC를 제공한다. 그러나 주 배포 선택은 d64L2이며, 이유는 저차원 특징만 사용하는 방식보다 원시 시계열의 표현 능력을 더 유지하면서도 실측 지연을 충분히 낮추기 때문이다.

8. 선행 연구와의 비교 및 논의

같은 NewHandPD 계열 데이터에서 96~99% 수준의 정확도를 보고한 연구가 여럿 존재하지만, 본 연구의 피험자 정확도는 80.5~84.9%로 더 낮다. 이 차이를 단순한 모델

우열로 해석하기보다는 평가 설계의 차이로 보는 것이 타당하다. NewHandPD는 파일 번호 66개에 비해 고유 피험자가 61명뿐이므로, 파일 단위 또는 이미지 단위 분할을 사용하면 동일 인물이 학습과 평가에 함께 들어갈 가능성이 있다. 본 연구는 피험자 단위 GroupKFold를 적용하고 연령 교란까지 별도로 통제했다.

연구	분할 단위 / 프로토콜	보고 성능
이미지 5-fold 계열 (2025)	클래스별 샘플 5-fold, 그룹 키 미확인	96.97 $\pm$ 1.27%
1D-CNN + BiGRU (2020)	65/10/25, 그룹 키 미확인	spiral ACC 94.44%, AUC .9825
Albani & sonbol (2026) [6]	이미지 단위 5-fold와 LOIO직접 비교	97.08% · 94.91%
Zhang (2025) [4]	원 논문 프로토콜 재현	spiral 84.03 $\pm$ 2.67%, meander 79.40 $\pm$ 3.52%
SVM 기반 (2026)	stratified 10-fold x 10	84.06%
Zhu (2025) [5]	NewHandPD를 외부 평가로만 사용	76.89%
본 연구	인물 단위 GroupKFold + 연령 매칭 (R5)	윈도우 AUC .851-.866; 피험자 .805-.849

표 7. 선행 연구의 분할 프로토콜과 보고 성능. 문헌 값은 원문 보고값이다.

표의 항목은 별도로 수행한 문헌 조사에서 수집한 값이며, 그룹 키가 명시되지 않은 연구를 잘못된 설계라고 단정하지 않는다. 다만 같은 프로토콜을 재현한 연구에서 84%대 성능이 나온 사례는, 96~99%대와 76~84%대 사이의 차이가 평가 단위에 의해 크게 달라질 수 있음을 시사한다.

선행 연구가 사람 단위 평가, 연령 교란, 재현성 검토, 외부 검증, 이미지 대 사람 단위 비교, 경량 특징 기반 분류 등을 개별적으로 다룬 것은 분명하다. 본 연구는 이 항목 각각의 최초성을 주장하지 않는다. 기여는 동일한 평가 조건에서 교란 통제와 설명 분석을 함께 수행하고, 그 조건에서 동적·정적·표현의 세 경량화 축을 비교했다는 데 있다.

9. 한계

- 표본 수: 총 61명이며, 두 교란을 동시에 통제하면 정상군이 8명만 남아 검정력이 크게 떨어진다.
- 검정력: 서브세 실험은 3-fold뿐이어서 이 표본에서 ± 0.15 규모의 변화는 검출하기 어렵다. 동등성 검정도 시드 3개 단위이며, 시드는 test 분할을 바꾸지 않으므로 새 피험자에 대한 동등성을 뜻하지 않는다.
- 오분류 표본: 일관 오분류 피험자가 2명뿐이어서, 어려운 표본의 실재를 통계적으로 강하게 주장하지 않는다.
- 실험 조건: 교란 통제(d64·1층, 15 epoch, 3-fold)와 깊이·경계 실험(p16d128, 50 epoch, 5-fold)은 모델과 학습 조건이 달라 결과를 직접 비교하지 않는다.

10. 결론

본 연구의 핵심 결과는 어려운 입력이 곧 더 많은 연산이 필요한 입력은 아니라는 것이다. 입력 난이도의 분산은 실제로 존재했지만, 깊이를 늘려도 일관 오분류 피험자는 구제되지 않았고, 시간 축에서는 일부 피험자가 더 빨리 확신 있게 틀렸다. 어려운 입력과 추가 연산으로 개선되는 입력이 일치하지 않으므로, 입력별로 연산을 배분하는 Early Exit은 이 과제에서 이득을 주지 못했다.

반면 패치 길이와 모델 폭을 줄이는 정적 경량화는 연산량과 실제 지연을 함께 낮췄다. 38 MFLOPs의 d64L2는 노트북 CPU 코어 하나에서 2초 신호를 7.8ms에 처리해 실시간의 약 256배 속도로 동작하며, 윈도우 AUC .851을 얻었다. 참조 모델 대비 연산량은 91배 적고 평균 AUC 차이는 .012였으나, 통계적 동등성은 확인되지 않았다. 54개 후보 중 4개 특징이 참조 모델 AUC의 약 93%를 얻어 소수 특징에도 상당한 판별력이 있었고, 설명 분석에서는 환자의 축압력 채널에서만 모델 근거 구간에 4-6Hz 대역이 유의하게 몰렸으며 정상군에서는 같은 효과가 나타나지 않았다.

다만 61명이라는 작은 표본과 제한된 검정력 때문에 이 결과를 모든 파킨슨 필기 데이터에 일반화할 수는 없다. 향후에는 실제 모바일·임베디드 기기에 모델을 이식해 배포 조건에서 지연과 에너지 비용을 검증하고, 더 큰 독립 코호트에서 같은 평가 프로토콜을 재현할 필요가 있다.