

R2 검증 실험 결과 보고서

기록(run) 시작·종료 윈도우 제거에 따른 L1 성능 변화

핵심 결론

각 기록의 첫 번째와 마지막 윈도우를 제거한 뒤에도 L1 모델의 윈도우 AUC 는 **0.8664 → 0.8691** 로 유지됐다. 평균 차이는 +0.0027 이며, 기록 시작·종료부 제거로 인한 성능 붕괴는 관찰되지 않았다.

단, 이 결과만으로 시작·종료 아티팩트에 대한 의론이 완전히 없다고 단정할 수는 없다. 앞뒤 창 제거로 학습량과 평가 창 구성도 함께 변했기 때문이다.

KEY METRICS

0.8691 R2 윈도우 AUC	+0.0027 기존 대비 AUC	11,890 R2 윈도우 수	61 명 피험자 유지
-----------------------------	-----------------------------	---------------------------	-----------------------

실험 목적

기록의 시작과 종료 구간에서 발생할 수 있는 측정 준비·종료 동작 등의 경계 아티팩트가 모델 성능에 과도하게 기여하는지 확인하기 위해, 각 run 의 첫·마지막 윈도우를 제거한 조건(R2)을 기존 L1 결과와 비교했다.

01 실행 조건

- 모델: p16d128L1 (588.2 MFLOPs, 136,206 parameters), RevIN ON
- 분할: Person_ID_Number 기준 GroupKFold 5-fold
- 반복: seed 42, 1, 7 (총 15 개 fold)
- R2 처리: 원본에서 먼저 fold 를 만든 뒤, 각 train / validation / test 에서 run 별 첫·마지막 창 제거

분할 고정 원칙: 윈도우 제거 전에 피험자 단위 fold 를 먼저 고정했기 때문에 윈도우 수 변화로 피험자가 다른 fold 로 이동하지 않는다. fold 별 피험자 명단과 인덱스 SHA256 은 results/r2_audit_s*.json 에 보존했다.

02 데이터 검증

항목	검증 결과	해석
윈도우	13,474 → 11,890	1,584 개 제거
기록(run)	792 개	유지
피험자	61 명	유지
정상 클래스	4,867 → 4,027	840 개 감소
환자 클래스	8,607 → 7,863	744 개 감소
인접 창 겹침	12,682 / 12,682 쌍	전부 일치

추가 무결성 확인

- 모든 run 의 순번 연속성 확인
- 피험자·라벨·과제 일관성 확인
- 각 fold 의 train / validation / test 피험자 중복 없음

03 시드별 결과

seed	윈도우 AUC	윈도우 정확도	피험자 hard	피험자 soft
42	0.8756	0.7915	0.9179	0.9179
1	0.8812	0.8065	0.8692	0.8859
7	0.8505	0.7516	0.8372	0.8705
평균	0.8691	0.7832	0.8748	0.8915

04 기존 L1 조건과 비교

지표	기존 L1	R2	차이
윈도우 AUC	0.8664	0.8691	+0.0027
윈도우 정확도	0.7805	0.7832	+0.0027
피험자 hard 정확도	0.8846	0.8748	-0.0098
피험자 soft 정확도	0.9068	0.8915	-0.0154

통계적 불확실성

R2 내부 95% 구간은 각 fold에서 세 seed를 평균한 뒤, 5개 fold의 산포를 이용해 계산한 근사 구간이다. 윈도우 AUC의 근사 95% 구간은 [0.7914, 0.9467]이다. 기존 결과에는 seed별 평균만 남아 있어 R2와의 대응 차이에 대한 TOST 또는 차이의 신뢰구간은 계산하지 않았다.

05 해석

관찰	기록 앞뒤 창을 제거해도 윈도우 AUC는 0.8664에서 0.8691로 유지됐다.
의미	시작·종료부를 제거했을 때 성능 붕괴가 없었으므로, 모델 성능이 기록 경계 정보에만 의존한다는 강한 증거는 관찰되지 않았다.
주의	앞뒤 창 제거와 동시에 학습량 및 평가 창 구성이 변했다. 따라서 R2만으로 경계 아티팩트 의존이 완전히 없다고 확정할 수는 없다.

피험자 정확도 해석

피험자 정확도는 한 사람이 약 1.6%p에 해당하고 seed·fold 변동의 영향이 크므로 AUC의 보조 지표로 해석한다. R2에서 피험자 정확도는 소폭 낮아졌지만 윈도우 AUC는 낮아지지 않았으며, 이 차이만으로 시작·종료 아티팩트 의존을 확정할 수 없다.

06 산출물 및 재현성

- fold 원본: results/folds_depth_p16d128L1_r2_2s*.csv
- 요약 CSV: results/r2_summary.csv
- 검증 기록: results/r2_audit_s42.json, r2_audit_s1.json, r2_audit_s7.json
- 학습 로그: results/r2_s42.log, r2_s1.log, r2_s7.log
- 실행 방법: bash run_r2.sh

R2 결론

기록의 경계 윈도우 제거 후에도 L1의 윈도우 AUC가 유지되었다. 따라서 R2에서는 시작·종료부 제거에 따른 성능 붕괴가 확인되지 않았다. 다만 아티팩트 의존 부재를 확정하려면 학습량과 평가 구성을 통제해 추가 검증이 필요하다.