

V2 — 사람마다 난이도가 다른가

원종윤 · 2026-09-07 (시드 3개 완료 반영)

가이드 05_실험_원종윤.md §M1-V2. ③단계의 본체다. 깊이 축과 시간 축은 "메커니즘이 작동하지 않았다"를 말하지만, 사람 축은 "애초에 배분할 난이도 차이가 없었다"를 말한다. 후자가 훨씬 강한 진술인데 지금까지 직접 켜 적이 없었다.

evaluate.py --save-probs가 남긴 확률을 재분석했다. 학습을 다시 돌리지 않았다.

참조 모델 p16d128L6, 5 fold × 3 seed(42, 1, 7).

개정 — 초판은 시드 42만 보고 "오분류가 5명에 집중"이라고 썼다. 시드 3개로 보니 그 서술이 과했다. 아래 §3에서 정정한다.

한 줄

가이드의 예상과 반대다. 난이도 차이는 있다. 다만 초판이 말한 것보다 약하다.

세 시드에서 모두 틀리는 피험자가 2명이고, 한 시드에서만 틀리는 사람이 6명이다.

없는 것은 난이도 분산이 아니라, 깊이가 그 어려운 사람을 구제하지 못한다는 연결고리다.

1. 피험자별 확률 분포

피험자 61명, 창 13,474개(사람당 82~801, 중앙 163). 아래는 시드 42 기준이다.

	n	평균 확률	SD	범위
정상	35	.242	.155	.005 ~ .517
환자	26	.694	.206	.157 ~ .972

두 군의 분리는 Mann-Whitney $p = 1.36e-09$ 이다.

사람 단위 평균 확률이 0.5에서 얼마나 떨어져 있는지가 그 사람이 얼마나 애매한지다.

|p - 0.5| 평균 .250 SD .151

0.1 미만 (애매) 13명 21.3%

0.3 이상 (확실) 24명 39.3%

다섯 명 중 한 명이 경계 근처에 있다. 확실한 사람과 애매한 사람이 실제로 나뉜다.

2. 창 수 편차는 분산 해석을 왜곡하지 않는다

가이드가 지적한 주의점이다. 피험자당 창이 82~801개로 10배 차이 나므로, 창이 많은 사람의 확률 분포가 더 안정적으로 보이는 것은 당연하다. 그것이 위 분산을 만든

것이라면 해석이 무의미해진다.

창 수 ↔ 창내 확률 SD Spearman $r = -0.007$ ($p = .959$)
창내 SD 평균 .254 범위 .012 ~ .443

상관이 사실상 0이다. 창 수 편차가 난이도 분산을 만들어낸 것이 아니다. 이 검증을 통과했으므로 이하 해석이 성립한다.

3. 오분류의 구조 — 초판을 정정한다

3-1. 시드마다 인원이 다르다

시드	틀린 피험자
42	5 / 61
1	8 / 61
7	8 / 61

초판은 시드 42의 5명만 보고 "오분류가 소수에 집중"이라고 썼다. 시드를 바꾸면 인원이 바뀐다.

3-2. 한 번이라도 틀린 사람은 12명이고, 그 안이 갈린다

재현	인원	해석
3 / 3 시드	2명	어떤 분할에서도 틀린다. 어려운 표본이 실재한다
2 / 3 시드	4명	경계에 있다
1 / 3 시드	6명	분할 노이즈

3/3으로 틀리는 2명은 둘 다 환자다.

정확한 진술은 "5명에 집중"이 아니라 이것이다.

오분류는 12명에 걸쳐 나타나며 그중 2명만이 분할과 무관하게 반복된다. 나머지 10명은 분할에 따라 달라진다. **핵심 2명 + 경계 4명 + 노이즈 6명**의 구조다.

3-3. 집중도 지표

시드 42 기준 사람별 창 오류율의 집중도다.

구성	틀린 피험자	창 오류율 Gini	상위 20% 점유
p16d128L1	8 / 61	.413	41.1%
p16d128L2	9 / 61	.466	45.5%
p16d128L3	5 / 61	.449	43.7%
p16d128L6	5 / 61	.448	44.0%

오류가 고르게 퍼졌다면 상위 20%가 20%를 차지해야 한다. 실제로는 44%로 2.2배다.

네 구성 모두 Gini가 .41~.47로 일정하다.

[!] 이 표는 시드 42 하나이므로 §3-2와 함께 읽어야 한다. 집중도 자체는 재현되거나 어느 사람에게 집중되는지는 2명을 제외하면 시드마다 다르다.

4. 깊이는 그 사람들을 구제하지 못한다

p16d128L1 ↔ p16d128L6, 시드 42 기준.

뒤집힌 피험자 5 / 61명 (8.2%)
 깊은 쪽이 고침 4명
 깊은 쪽이 망침 1명
 순이득 +3명

확률 변화폭 |L1 - L6| 평균 .083 최대 .585

층을 다섯 개 더 쌓아서 순이득이 3명이었고, 사람 단위 확률이 평균 .083밖에 움직이지 않는다. **3/3 시드로 틀리는 2명은 L1에서도 L6에서도 틀린다.**

5. 틀리는 사람이 누구인가 (V2-b)

교란(수집 시기·나이) 쪽 사람인지 병리적으로 어려운 사람인지 가렸다. 시드 42 기준.

구분	나이	연도	창수	평균확률	폴더	
정상	30	2010	152	.517	H13	
환자	55	2011	560	.157	P15W	P17
환자	65	2011	143	.358	P6	
환자	56	2011	176	.455	P20	
환자	55	2011	175	.460	P23	

연도별

연도	인원	틀림	비율
2010	7	1	14.3%
2011	32	4	12.5%
2012	1	0	0.0%
2016	21	0	0.0%

나이 구간별

구간	인원	틀림	비율
0~45	20	1	5.0%
45~55	10	0	0.0%
55~65	26	3	11.5%
65~100	5	1	20.0%

판정

가설	판정	근거
나이 지름길	약화	나이 구간별 오분류가 반대 방향이다. 나이로 찍는다면 나이 많은 정상 에서 틀려야 하는데 실제로는 나이 많은 환자 에서 틀린다. 순열 $p = .697$
시기 지름길	배제 못 함	2016년 21명이 전원 정답이다. "2016 = 정상"을 외웠다면 정상은 다 맞고 환자에서 틀리는 것이 맞는데, 실제 패턴이 그렇다(틀린 5명 중 4명이 환자). 순열 $p = .112$

경계 근처 13명으로 표본을 넓혀 봐도 나이 $p = .250$, 연도 $p = .428$ 로 유의하지 않다.

****나이 쪽은 어느 정도 배제되나 시기 쪽은 열려 있다. R4(2016년 21명 제외)를 실제로 돌려야 갈린다.**** ②단계이며 임시연 담당이다.

눈에 띄는 한 명

P15|P17은 창이 560개로 압도적으로 많고(중앙값 163) 확률 .157로 가장 확신 있게 틀린다. **우림이 찾은 중복 4쌍 중 하나다.** 두 파일 번호가 한 사람이므로 창이 2배로 들어가 학습에서 과대표현됐을 수 있다.

6. ③단계 결론 수정

가이드 02는 세 방향 모두 조건 불성립이라고 적었다. **사람 측은 조건이 성립한다.**

전제	판정	근거
(a) 층을 쌓으면 나아진다	불성립	순이득 3명, 확률 변화 .083
(b) 어려운 표본이 존재한다	성립(약)	3/3 시드로 틀리는 2명. Gini .45

어려운 표본은 존재한다. 다만 분할과 무관하게 반복되는 것은 2명이며, 나머지 오분류는 분할에 따라 바뀐다. 그리고 **깊이를 늘려도 그 2명이 구제되지 않는다.** Early Exit이 실패한 이유는 난이도 분산의 부재가 아니라, **난이도와 깊이 요구량이 연결되어 있지 않기 때문이다.**

이 편이 방어하기 쉽다. "난이도 차이가 없다"는 확률 분포 하나만 보여 달라고 하면 반박당한다. 실제로 분포가 갈리기 때문이다.

[!] 다만 **"어려운 표본이 존재한다"를 2명으로 주장하는 것은 약하다.** 61명 중 2명이며 신뢰구간을 붙일 표본이 아니다. 논문에는 "재현되는 오분류가 소수 존재하나 그 규모가 작아 단정하지 않는다"로 쓰는 것이 정확하다.

7. 한계

3/3 시드 오분류가 2명이다. 통계적 주장을 하기에 너무 작다.

Gini와 상위 20% 점유는 시드 42 하나에서 계산했다. 신뢰구간을 붙이려면 부트스트랩이 필요하다.

R4·R5(② 단계)를 통과하기 전이므로, "어려운 사람"이 병리적으로 어려운 것인지 수집 시기 때문인지 아직 완전히 가릴 수 없다. §5에서 나이는 악화됐으나 시기는 남아 있다.

재현

```
python exp_v2.py  
python exp_v2b.py
```

results/probs_p16d128L{1,2,3,6}_depth_2s{,_s1,_s7}.npz를 읽는다. 학습은 필요 없다.