

V3 [B] — 시간 축 사전 점검, 그리고 ③단계 종합

원종윤 · 2026-09-07

가이드 05_실험_원종윤.md §M1-V3, 설계는 paper/exp2_protocol.md §2. **학습 없이 numpy 재계산만으로 실험 2의 성립 여부가 판정되는 게이트다.**

한 줄

게이트를 통과하지 못했다. 사전 등록 기준으로 C 유형(확신을 갖고 오분류)이 3시드 평균 8명이며, 8명 이상은 "재설계"다. 다만 **관측량 절감의 이론적 여지는 98.5%로 매우 크다. **시간 축은 "이득이 없어서"가 아니라 "오류를 통제할 수 없어서"** 막힌다.

1. 무엇을 잰나

시험자 s마다 창별 증거를 누적했을 때 판정에 몇 개가 필요한지를 추정한다.

원도우별 증거 $e_i = \text{logit}(p_i) - c$
드리프트 $d_s = \text{mean}(e_i)$ 한 창당 평균 증거
필요 관측량 $n^*_s = A / |d_s|$ Wald 근사
 $A = \log((1-\beta)/\alpha) = 2.944 \quad (\alpha = \beta = .05)$

확률 공급원은 **정적 L1**이다(exp2_protocol.md §1-1). 같은 층 수에서 정적 학습이 EE 출구보다 일관되게 높고, 이렇게 하면 실험 2가 earlyexit.py에서 독립한다.

유형	조건	의미
A 물표	부호 일치 · $n^* \leq 10$	빨리 종료. 시간 절감이 나오는 곳
B 접전	부호 일치 · $n^* > 10$	오래 봐야 함. 유보 대상
C 반대	부호 불일치	확신을 갖고 오분류

2. 결과

시드 42 기준 유형 분류다. n^* 기준을 바꿔 가며 민감도를 확인했다.

기준	A 물표	B 접전	C 반대
$n^* \leq 5$	43	10	8
$n^* \leq 10$	52	1	8
$n^* \leq 20$	53	0	8

C는 기준과 무관하다. 부호 문제이지 관측량 문제가 아니기 때문이다.

사전 등록된 판정 (§2-4)

C 인원	판정
0~3	진행
4~7	조건부 진행 — 유보 옵션과 비대칭 경계 필수
8 이상	재설계 — 정지 규칙이 아니라 모델·특징 문제

시드	C 인원	판정
42	8	재설계
1	7	조건부 진행
7	9	재설계

평균 8명으로 경계에 걸린다. 세 시드 중 둘이 재설계이므로 게이트 불통과로 본다.

가장 나쁜 시드를 기준으로 보는 것이 게이트의 취지에 맞다.

C 유형 명단 (시드 42)

구분	창수	드리프트	n*
환자	143	-1.137	2.6
환자	175	-1.085	2.7
환자	176	-0.663	4.4
환자	155	-0.570	5.2
환자	270	-0.478	6.2
환자	229	-0.460	6.4
정상	166	+0.446	6.6
환자	217	-0.173	17.0

8명 중 7명이 환자다. n*가 2.6이라는 것은 창 3개만 보고 멈춘다는 뜻인데 그 답이 틀리다. **SPRT를 붙이면 더 빨리, 더 확신 있게 틀린다.** 관측을 늘려도 고쳐지지 않는다. 방향 자체가 반대이기 때문이다.

3. 사전확률 보정 c 가 판정을 흔드는가 — 흔들지 않는다

프로토콜 §1-2는 캘리브레이션을 반드시 val에서 하라고 한다. 현재 확률 파일에 val이 없어 전체 창 양성률(.639)의 로짓으로 c를 근사했다. 이 근사가 판정을 바꾸는지 확인했다.

c	유래	C 인원	판정
-0.297	피험자 양성률 .426	8	재설계
0.000	보정 없음	9	재설계
+0.570	창 양성률 .639	8	재설계
+1.000	임의	11	재설계

c	유래	C 인원	판정
+2.000	임의	18	재설계

c를 -3 ~ +4 전 구간에서 훑어도 $C \leq 7$ 이 되는 c가 없다. 최소값이 8명이다.

따라서 val 확률을 확보해 fold별로 정확한 c를 구해도 판정은 같다. 재학습이 필요 없다.

온도 보정 T도 마찬가지다. T는 로짓을 상수배 하므로 부호를 바꾸지 않는다.

C 인원은 캘리브레이션과 무관하다.

4. 그런데 절감 여지는 매우 크다

이것이 깊이 축과 갈리는 지점이다.

필요 관측량 n^* (사람당 실제 창 82~801, 중앙 163)

$n^* \leq 5$ 46명 (75.4%)

$n^* \leq 10$ 59명 (96.7%)

$n^* \leq 20$ 61명 (100%)

n^* 중앙 2.0 → 실제 창 중앙의 1.2%

이론적 관측량 절감 상한 98.5%다. 각자 n^* 개만 보고 멈춘다고 가정한 값이며 실제 SPRT는 이보다 못하다.

드리프트 분포는 단봉이 아니다

프로토콜 §2-3은 분포가 단봉이면 적응적 종료의 이론적 이득이 0이라고 적었다.

|d_s| 평균 1.904 중앙 1.496 SD 1.476 범위 0.173 ~ 5.908

분위 10/25/50/75/90 0.41 / 0.63 / 1.50 / 3.06 / 4.16

상위 25% / 하위 25% = 4.8배

명확도가 사람마다 4.8배 갈린다. 단봉이 아니므로 이론적 이득이 존재한다.

드리프트는 신뢰도의 대리 지표로 작동한다

|d_s| ↔ 판정 적중 점이연 상관 $r = +0.339$ ($p = .007$)

드리프트가 큰 사람이 실제로 더 맞는다. **멈출 시점을 정하는 신호로 쓸 수 있다.**

5. 그래서 무엇이 막는가

조건	판정	값
절감 여지가 있는가	[O]	이론 상한 98.5%
난이도 분산이 있는가	[O]	상하위 4.8배, 단봉 아님

조건	판정	값
멈출 신호가 있는가	[O]	$r = +0.34$
오류를 통제할 수 있는가	[X]	C 8명 — 명목 α 보장 불가

세 조건이 갖춰졌는데 네 번째에서 막힌다. "시간을 아낄 수 있나"는 예스이고, "안전하게 아낄 수 있나"는 노다.

이것은 "시간 축은 조건이 성립하지 않는다"보다 훨씬 구체적인 진술이다.

6. ③단계 종합 — 세 방향

가이드 02는 세 방향 모두 "조건 불성립"이라고 적었다. **세 방향의 실패 양상이 서로 다르므로 그 서술을 나눠야 한다.**

6-1. 깊이 (V1) — 팀 프로토콜 재측정

5 fold $\times$ 3 seed. 08 §2 보고 규칙에 따라 fold 안에서 시드를 평균한 뒤 fold 사이 산포로 90% 신뢰구간을 냈다.

구성	MFLOPs	창 AUC	피험자 acc	시드 재현 SD
p16d128L1	588	.8643 $\pm$.0512	.8731 $\pm$.0649	.0108
p16d128L2	1,170	.8648 $\pm$.0658	.8581 $\pm$.0728	.0113
p16d128L3	1,752	.8569 $\pm$.0712	.8902 $\pm$.0755	.0158
p16d128L6	3,499	.8615 $\pm$.0716	.8859 $\pm$.0305	.0160

L6 대비 짝지은 차이(fold 단위)다.

구성	Δ 창 AUC	부호	t(4)	90% CI
L1	+0.28%p	2/5	+0.18	[-2.92, +3.48]
L2	+0.33%p	2/5	+0.63	[-0.80, +1.47]
L3	-0.46%p	2/5	-0.56	[-2.22, +1.30]

연산을 6배 써서 창 AUC가 개선되지 않는다. 세 조건 모두 부호가 2/5로 엇갈린다.

[!] 신뢰구간이 넓다. L1의 구간이 $\pm 3.48\%$ 이고 층 간 차이는 0.3%p 수준이다.

층 차이보다 fold 간 산포가 10배 크다. "차이가 없다"가 아니라 "이 표본에서 검출할 수 있는 크기가 아니다"가 정확하다.

6-2. 사람 (V2)

난이도 분산은 존재한다. 다만 3/3 시드로 반복되는 오분류는 2명이며, 나머지는 분할에 따라 바뀐다. 깊이를 늘려도 그 2명이 구제되지 않는다(순이득 3명, 확률 변화 .083).

6-3. 시간 (V3)

절감 여지 98.5%, 난이도 분산 4.8배, 신뢰도 대리 $r = +0.34$ 로 조건이 갖춰졌으나 C 유형 8명으로 오류 통제가 불가능하다.

6-4. 관통하는 진술

축	메커니즘	어려운 사람
깊이	층을 더 쌓을 수 있다	구제되지 않는다
시간	더 오래 볼 수 있다	더 빨리 확신 있게 틀린다
사람	난이도 차이가 있다	그 차이가 계산량과 연결되지 않는다

세 방향 모두 "메커니즘은 작동하는데 어려운 사람에게 들지 않는다"다.
Early Exit이 실패한 이유는 난이도 분산의 부재가 아니라, **난이도와 계산량 요구가 연결되어 있지 않기 때문이다.** 더 쓰면 나아지는 표본과 실제로 어려운 표본이 서로 다른 집합이다.

이 서술은 가이드 02의 "세 방향 모두 조건 불성립"을 대체한다. 조건은 상당 부분 성립하며, 성립하지 않는 것은 **연결**이다.

7. 남은 것

[C]~[E]	실행하지 않는다. 게이트 불통과
E3 채널 제거	학습 필요. 깊이 축이 끝났으므로 지금 가능
R4-R5	②단계, 임시연 담당. V2 §5의 시기 지름길이 여기서 갈린다

재현

```
python analyze_drift.py          # 기본 정적 L1
python analyze_drift.py --cfg p16d128L6  # 참조 모델로도 확인
```

results/probs_p16d128L1_depth_2s{s1,s7}.npz를 읽는다. 학습은 필요 없다.